

Paquete de Python para el procesamiento de imágenes usando varios modelos no lineales

Carlos Toledo Silva

Tutor
MSc. Damian Valdés Santiago

Universidad de La Habana

13 de diciembre 2022

Puntos claves:

- El Procesamiento Lineal Clásico de Imágenes tiene limitaciones.
- Oppenheim (1965) introduce la teoría homomórfica.
- Jourlin y Pinoli (1988) proponen el primer modelo logarítmico para el procesamiento de imágenes.
- Patrascu y Buzuloiu (2001) proponen un modelo logarítmico simétrico.
- Vertan y colaboradores (2008) proponen el modelo pseudo-logarítmico.
- Diversas aplicaciones: corrección de iluminación, mejora de contraste, mejora de imagen en color, ecualización de histogramas, mejora de rango dinámico, detección de bordes, etc.

Introducción – Objetivos

Objetivos:

- Diseño e implementación de un módulo de Python donde se encuentren los modelos no lineales para el procesamiento de imágenes abordados en este trabajo.
- Evaluación de los diferentes modelos en cuanto a las diferentes operaciones, tipos de imágenes y situaciones.

Tareas de investigación:

- Revisar la literatura referente a los modelos no lineales para el procesamiento de imágenes.
- Implementación en Python de los diferentes modelos a partir de la bibliografía consultada.
- Creación de *datasets* con diferentes tipos de imágenes para evaluar los modelos.
- Selección de métricas para la evaluación de los modelos.
- Evaluación de los modelos.
- Arribar a conclusiones sobre la eficacia y utilidad de estos modelos.

Definición

Sean (E, K, \oplus, \otimes) y $(F, K, +, \cdot)$ dos estructuras algebraicas, $K \subseteq \mathbb{R}$, se denomina homomorfismo a la relación $\varphi : E \rightarrow F$ que satisface:

$$\varphi(u \oplus v) = \varphi(u) + \varphi(v), \forall u, v \in E, \quad (1)$$

$$\varphi(\alpha \otimes u) = \alpha \cdot \varphi(u), \forall u \in E, \forall \alpha \in K. \quad (2)$$

La admisión de un inverso y la existencia de biyectividad indica la presencia de un isomorfismo.

En este trabajo:

- $E \subseteq \mathbb{R}$, conjunto de valoración de las imágenes.
- $F \subseteq \mathbb{R}$, conjunto de valoración de las estructuras vectoriales. Si $u \in E$ entonces $\varphi(u) \in F$.
- $I(D, E)$ conjunto de imágenes definidas en $D \subset \mathbb{R}^2$ y valoradas en E .
- $I(D, F)$ conjunto de las estructuras vectoriales definidas en $D \subset \mathbb{R}^2$ y valoradas en F . Si $f \in I(D, E)$ entonces $\varphi(f) \in I(D, F)$.

Una imagen en niveles de gris toma sus valores (niveles de gris) en la escala de grises $[0, M]$. Para imágenes de 8 bits, $M = 256$ y los 256 niveles de gris están en la escala de números enteros $[0, \dots, 255]$.

Con respecto a la restricción de biyectividad y la existencia de φ^{-1} , las leyes de definición están determinadas por:

$$u \oplus v = \varphi^{-1}(\varphi(u) + \varphi(v)), \quad (3)$$

$$\alpha \otimes u = \varphi^{-1}(\alpha \cdot \varphi(u)). \quad (4)$$

Propiedad de cierre:

$$\forall u, v \in E, z = u \oplus v \Rightarrow z \in E, \quad (5)$$

$$\forall u \in E, \forall \alpha \in K, z = \alpha \otimes v \Rightarrow z \in E. \quad (6)$$

Definición

Dados los dos operadores, \oplus , \otimes , el conjunto vectorial E y el conjunto escalar K , la definición formal de espacio vectorial implica que:

- *La ley de la suma debe ser asociativa, conmutativa, debe tener elemento identidad y elemento inverso*
- *La distributividad debe mantenerse para la multiplicación escalar sobre la suma de vectores y para la multiplicación escalar en el espacio de los escalares.*
- *La multiplicación escalar debe tener elemento identidad y ser compatible con la multiplicación en el espacio de los escalares.*

Las propiedades conmutativas, asociativas y distributivas se pueden comprobar.

Estado del Arte – Antecedentes Matemáticos

Elemento identidad con respecto a la suma:

$$\forall u \in E, \exists u_0 : u \oplus u_0 = u | \varphi(u_0) = 0. \quad (7)$$

Elemento inverso con respecto a la suma:

$$\forall u \in E, \exists u^- \Rightarrow u \oplus u^- = u_0 | \varphi(u) + \varphi(u^-) = 0 \Rightarrow \varphi(u^-) = -\varphi(u). \quad (8)$$

Elemento identidad de la multiplicación escalar tiene que ser 1:

$$\forall u \in E - \{u_0\}, \exists \alpha_1 : \alpha_1 \otimes u = u | \alpha_1 = 1. \quad (9)$$

Definición

Sea V un espacio vectorial real y K , el conjunto escalar. Un cono C en V es un subconjunto de V que satisface:

- 1 si $u_1, u_2 \in C$ y $\alpha, \beta \in K : \alpha, \beta \geq 0$, entonces $\alpha u_1 + \beta u_2 \in C$.
- 2 $C \cap (-C) = 0$.

Nombre: Modelo Logarítmico Clásico para el Procesamiento de Imágenes.

Propuesto por: Jourlin y Pinoli (1988).

Dominio: $E = [0, M] \cup E = (-\infty, M)$.

Funciones de cambio: $v = M - u$, $u = M - v$.

Suma: $v_1 \oplus v_2 = v_1 + v_2 - \frac{v_1 v_2}{M}$.

Multiplicación por un escalar: $\lambda \otimes v = M - M \left(1 - \frac{v}{M}\right)^\lambda$.

Opuesto: $\ominus v = -\frac{v}{1 - \frac{v}{M}}$.

Resta: $v_1 \ominus v_2 = \frac{v_1 - v_2}{1 - \frac{v_2}{M}}$.

Función del isomorfismo: $\varphi(v) = -M \ln \left(1 - \frac{v}{M}\right)$.

Inversa de la función del isomorfismo: $\varphi^{-1}(x) = M \left(1 - e^{-\frac{x}{M}}\right)$.

Propiedades:

- La suma \oplus es asociativa, conmutativa, tiene un elemento identidad: 0 y cada elemento tiene un opuesto.
- La multiplicación escalar \otimes es asociativa, tiene elemento identidad: 1 y la distributividad se mantiene para la multiplicación escalar sobre \oplus y para la multiplicación escalar en el espacio de los escalares.

Si $E = [0, M]$ entonces $(E, \mathbb{R}^+, \oplus, \otimes)$ es un cono positivo.

Si $E = (-\infty, M]$ entonces $(E, \mathbb{R}, \oplus, \otimes)$ es un espacio vectorial.

Estado del Arte – Modelo HLIP

Nombre: Modelo Logarítmico Homomórfico para el Procesamiento de Imágenes.

Propuesto por: Patrascu y Buzuloiu (2001).

Dominio: $E = (-1, 1)$.

Funciones de cambio: $v = \frac{2}{M} \left(u - \frac{M}{2} \right)$, $u = \frac{M}{2}(v + 1)$.

Suma: $v_1 \oplus v_2 = \frac{v_1 + v_2}{1 + v_1 v_2}$.

Multiplicación por un escalar: $\lambda \otimes v = \frac{(1+v)^\lambda - (1-v)^\lambda}{(1+v)^\lambda + (1-v)^\lambda}$, $\lambda \in \mathbb{R}$.

Opuesto: $\ominus v = -v$.

Resta: $v_1 \ominus v_2 = \frac{v_1 - v_2}{1 - v_1 v_2}$.

Función del isomorfismo: $\varphi(v) = \frac{1}{2} \ln \left(\frac{1+v}{1-v} \right)$.

Inversa de la función del isomorfismo: $\varphi^{-1}(x) = \frac{e^{2x} - 1}{e^{2x} + 1}$.

Propiedades:

- La suma \oplus es asociativa, conmutativa, tiene un elemento identidad: 0 y cada elemento tiene un opuesto.
- La multiplicación escalar \otimes es asociativa, tiene elemento identidad: 1 y la distributividad se mantiene para la multiplicación escalar sobre \oplus y para la multiplicación escalar en el espacio de los escalares.

La estructura $(E, \mathbb{R}, \oplus, \otimes)$ es un espacio vectorial.

Estado del Arte – Modelo PSLIP

Nombre: Modelo Pseudo-logarítmico para el Procesamiento de Imágenes.

Propuesto por: Vertan y colaboradores (2008).

Dominio: $E = [0, 1]$.

Funciones de cambio: $v = \frac{u}{M}$, $u = M \cdot v$.

Suma: $v_1 \oplus v_2 = \frac{v_1 + v_2 - 2v_1 v_2}{1 - v_1 v_2}$.

Multiplicación por un escalar: $\lambda \otimes v = \frac{\lambda v}{1 + (\lambda - 1)v}$, $\lambda \in \mathbb{R}^+$.

Resta: $v_1 \ominus v_2 = \frac{v_1 - v_2}{1 + v_1 v_2 - 2v_2}$: $v_1 \geq v_2$.

Función del isomorfismo: $\varphi(v) = \frac{v}{1-v}$.

Inversa de la función del isomorfismo: $\varphi^{-1}(x) = \frac{x}{1+x}$.

Propiedades:

- La suma \oplus es asociativa, conmutativa y tiene un elemento identidad: 0.
- La multiplicación escalar \otimes es asociativa, tiene elemento identidad: 1 y la distributividad se mantiene para la multiplicación escalar sobre \oplus y para la multiplicación escalar en el espacio de los escalares.

La estructura $(E, \mathbb{R}^+, \oplus, \otimes)$ es un cono positivo. La extensión a un espacio vectorial se puede lograr mediante el uso de la función generadora definida en $(-1, 1) \rightarrow (-\infty, +\infty) : \varphi(v) = \frac{v}{1-|v|}$.

Estado del Arte – Modelo PLIP

Nombre: Modelo Logarítmico Parametrizado para el Procesamiento de Imágenes.

Propuesto por: Panetta y colaboradores (2010).

Dominio: $E = [0, M] \cup E = (-\infty, M)$.

Funciones de cambio: $v = \mu(M) - u$, $u = \mu(M) - v$.

Suma: $v_1 \oplus v_2 = v_1 + v_2 - \frac{v_1 v_2}{\gamma(M)}$.

Multiplicación por un escalar: $c \otimes v = \gamma(M) - \gamma(M)(1 - \frac{v}{\gamma(M)})^c$.

Opuesto: $\ominus v = -\frac{v}{1 - \frac{v}{\gamma(M)}}$.

Resta: $v_1 \ominus v_2 = \frac{v_1 - v_2}{1 - \frac{v_2}{\gamma(M)}}$.

Función del isomorfismo: $\varphi(v) = -\lambda(M) \ln^\beta \left(1 - \frac{v}{\lambda(M)}\right)$.

Inversa de la función del isomorfismo: $\varphi^{-1}(x) = \lambda(M) \left(1 - \left(e^{-\frac{x}{\lambda(M)}}\right)^{\frac{1}{\beta}}\right)$.

Propiedades:

- Las operaciones aritméticas lineales se reemplazan con nuevas operaciones de la misma manera que en el modelo LIP.
- Las operaciones son iguales a las del modelo LIP cuando $\mu(M) = \gamma(M) = k(M) = \lambda(M) = M$ y $\beta = 1$.
- Las operaciones se asemejan a las operaciones aritméticas lineales a medida que $\gamma(M)$, $k(M)$ y $\lambda(M)$ se aproximan al infinito.
- Las operaciones pueden generar más casos entre los dos casos extremos del LIP y las operaciones aritméticas lineales cuando los parámetros μ , γ , k y λ cambian dentro de $[M, +\infty)$.
- Las operaciones cumplen las leyes de asociatividad, conmutatividad, elemento identidad, elemento opuesto para la suma y las propiedades distributivas.

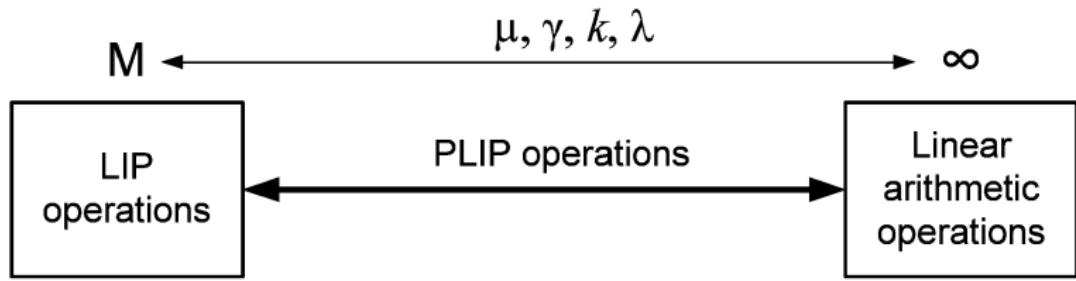


Figura: Operaciones en el modelo PLIP

Estado del Arte – Modelo SLIP

Nombre: Modelo Logarítmico Simétrico para el Procesamiento de Imágenes.

Propuesto por: Navarro y colaboradores (2013).

Dominio: $E = (-M, M)$.

Suma: $v_1 \oplus v_2 = M \cdot \text{sgn}(v_1 + v_2) \left[1 - \left(1 - \frac{|v_1|}{M} \right)^{\gamma_1} \left(1 - \frac{|v_2|}{M} \right)^{\gamma_2} \right],$

$$\gamma_1 = \frac{\text{sgn}(v_1)}{\text{sgn}(v_1+v_2)}, \quad \gamma_2 = \frac{\text{sgn}(v_2)}{\text{sgn}(v_1+v_2)}.$$

Multiplicación por un escalar: $\lambda \otimes v = M \cdot \text{sgn}(\lambda v) \left[1 - \left(1 - \frac{|v|}{M} \right)^{|\lambda|} \right].$

Opuesto: $\ominus v = (-1) \otimes v.$

Resta: $v_1 \ominus v_2 = v_1 \oplus (-1) \otimes v_2.$

Función del isomorfismo: $\varphi(v) = -M \cdot \text{sgn}(v) \ln \left(1 - \frac{|v|}{M} \right).$

Inversa de la función del isomorfismo: $\varphi^{-1}(x) = M \cdot \text{sgn}(x) \left(1 - e^{-\frac{|x|}{M}} \right).$

Propiedades:

- La suma \oplus es asociativa, conmutativa, tiene un elemento identidad: 0 y cada elemento tiene un opuesto.
- La multiplicación escalar \otimes es asociativa, tiene elemento identidad: 1 y la distributividad se mantiene para la multiplicación escalar sobre \oplus y para la multiplicación escalar en el espacio de los escalares.

La estructura $(E, \mathbb{R}, \oplus, \otimes)$ es un espacio vectorial.

Nombre: Modelo Pseudo-logarítmico Parametrizado para el Procesamiento de Imágenes.

Versión inicial: Parametrizar las funciones de cambio

Se parametrizan solo las funciones de cambio de la siguiente forma:

$$v = \frac{u}{\delta(M)}, \quad u = \delta(M)v$$

tal que $\delta(M) \geq M$ y mantener el dominio y el resto de operaciones del modelo PSLIP.

Ventaja: Se parametriza el modelo para evitar la pérdida de información.

Desventaja: Las operaciones se parametrizan con el mismo parámetro.

Versión final: Eliminar las funciones de cambio y hacer los cambios directamente en las operaciones.

Dominio: $E = [0, M]$.

Suma: $u_1 \oplus u_2 = \frac{u_1 + u_2 - \frac{2u_1 u_2}{\gamma(M)}}{1 - \frac{u_1 u_2}{\gamma(M)^2}}$.

Multiplicación por un escalar: $c \otimes u = \frac{cu}{1 + \frac{(c-1)u}{\gamma(M)}}$.

Resta: $u_1 \ominus u_2 = \frac{u_1 - u_2}{1 + \frac{u_1 u_2}{k(M)^2} - \frac{2u_2}{k(M)}}$: $u_1 \geq u_2$.

Función del isomorfismo: $\varphi(u) = \frac{u}{\lambda(M) - u}$.

Inversa de la función del isomorfismo: $\varphi^{-1}(x) = \lambda(M) \frac{x}{1+x}$.

Propiedades:

- Las operaciones aritméticas lineales se reemplazan con nuevas operaciones de la misma manera que en el modelo PSLIP.
- Las operaciones son iguales a las del modelo PSLIP cuando $\gamma(M) = k(M) = \lambda(M) = M$.
- Las operaciones se asemejan a las operaciones aritméticas lineales a medida que $\gamma(M)$, $k(M)$ y $\lambda(M)$ se aproximan al infinito.
- Las operaciones pueden generar más casos entre los dos casos extremos del PSLIP y las operaciones aritméticas lineales cuando los parámetros γ , k y λ cambian dentro de $[M, +\infty)$.
- Las operaciones cumplen las leyes de asociatividad, conmutatividad, elemento identidad y las propiedades distributivas.

Propuesta – Módulo Implementado – Estructuras

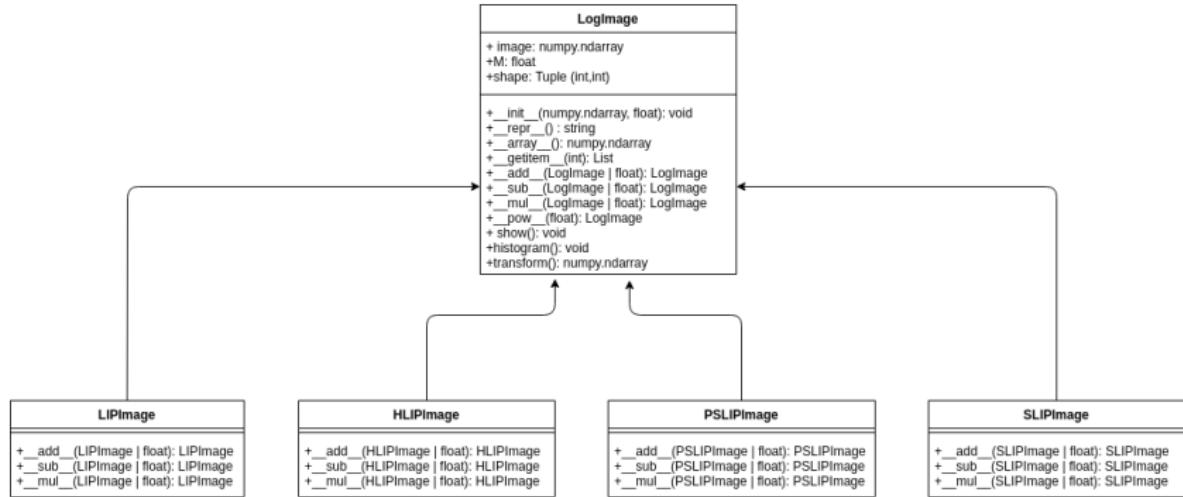


Figura: Diagrama de clases de las estructuras no lineales.

Propuesta – Módulo Implementado – Espacios

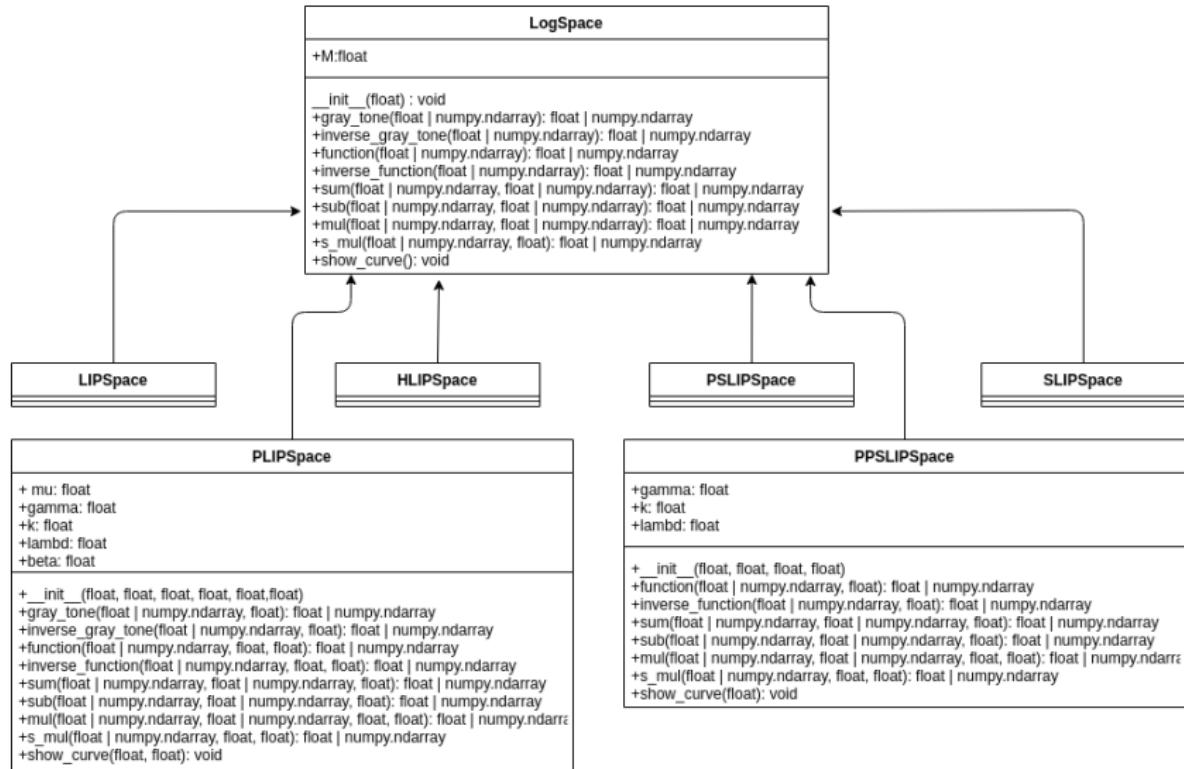


Figura: Diagrama de clases de los espacios no lineales.

La Medida de Mejora por Entropía se calcula dividiendo una imagen I en $k_1 \times k_2$ bloques, obteniendo el máximo local $I_{maxk,I}$ y el mínimo $I_{mink,I}$ dentro de cada bloque individualmente, y luego procesándolos usando la siguiente ecuación:

$$EMEE_{\alpha, k_1, k_2} = \sum_{l=1}^{k_1} \sum_{k=1}^{k_2} \alpha \left(\frac{I_{maxk,I}}{I_{mink,I}} \right)^\alpha \ln \left(\frac{I_{maxk,I}}{I_{mink,I}} \right), \quad (10)$$

donde α es una constante que puede ayudar a seleccionar los parámetros. Se eligió $\alpha = 1$ y el tamaño de bloque 4×4 , 4×5 , 5×4 y 5×5 , según las dimensiones de la imagen.

El mejor parámetro (óptimo) se obtiene si se cumple la siguiente condición:

$$EMEE_{optimal} = \max_{local}(EMEE(\alpha, \mu, \gamma, k, \lambda, \beta)) \quad (11)$$

Esta medida se utilizó para obtener las mejores combinaciones de parámetros en el modelo PLIP.

El contraste absoluto entre dos píxeles distintos $p_1, p_2 \in D$, para una imagen, $f \in I(D, E)$ se define:

$$C_A(p_1, p_2) = \frac{1}{d(p_1, p_2)} \cdot \frac{|f(p_1) - f(p_2)|}{1 - \frac{f(p_1) \cdot f(p_2)}{M^2}}, \quad (12)$$

Luego de experimentos, se decidió modificar la ecuación anterior, cambiando la definición a:

$$C_A(p_1, p_2) = \frac{|f(p_1) - f(p_2)|}{d(p_1, p_2)} \cdot \frac{256}{M} \quad (13)$$

El contraste para un píxel arbitrario $p \in D$, para una imagen $f \in I(D, E)$, se define por la media del contraste absoluto entre el píxel p y los píxeles $(p_i)_{i=1,\dots,n}$ que pertenecen a una vecindad V :

$$C(p) = \frac{1}{n} \sum_{i=1}^n C_A(p, p_i). \quad (14)$$

Luego el valor de C_p de una imagen es el promedio de los valores de $C(p)$ de los pixeles que la conforman.

Propuesta – Módulo Implementado – Algoritmos

Detección de bordes

Se utilizan diferentes filtros como Sobel, Prewitt, Scharr, etc. En particular los tres mencionados anteriormente aparecen implementados en la librería `skimage.filters` de Python.

Unsharp masking

Unsharp Masking es una técnica para mejorar la calidad de una imagen. Esta técnica consiste en determinar los bordes de una imagen y luego fusionar la imagen original con la imagen de bordes de dicha imagen.

Transformación Afín

Transformación afín $\psi : I(D, E) \rightarrow I(D, E) : E = (a, b)$, para una imagen $f \in I(D, E)$ cuya media es μ_f y su varianza es σ_f^2 :

$$\psi(f) = \frac{\sigma_u}{\sigma_f} \otimes (f \ominus \mu_f). \quad (15)$$

Importante: Este algoritmo solo se puede utilizar en espacios vectoriales acotados.

Detalles de Implementación – Estructura del Módulo

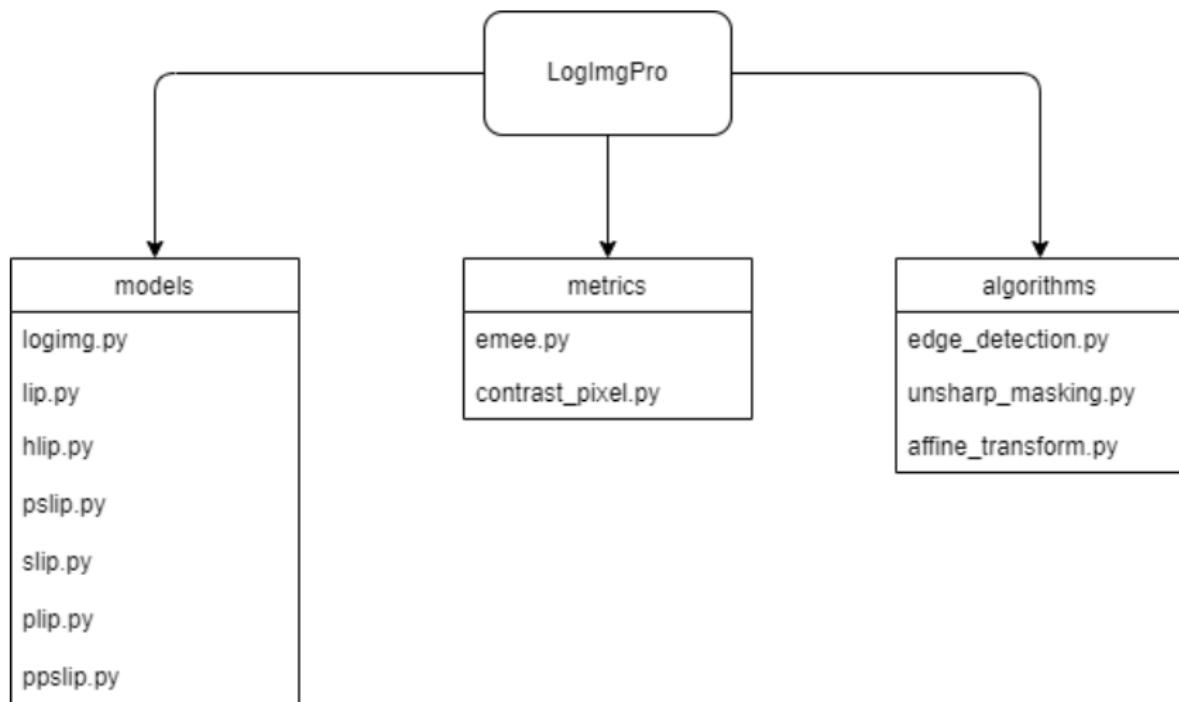


Figura: Diagrama de la estructura del módulo.

Detalles de Implementación – Modelos

Las imágenes en niveles de gris se definen en el intervalo $[0, M]$.

Problema con los modelos LIP y HLIP pues, si u es un nivel de gris, v su tono de gris correspondiente y $u = 0$ entonces:

- LIP: $v = M - u = M - 0 = M$. Contradicción $E = [0, M]$.
- HLIP: $v = \frac{2}{M}(u - \frac{M}{2}) = \frac{2}{M}(0 - \frac{M}{2}) = \frac{2}{M}(-\frac{M}{2}) = -1$. Contradicción $E = (-1, 1)$

Solución: Antes de cambiar la imagen de niveles de gris a tonos de gris, esta primero se procesa de tal forma que el menor valor admisible sea un número cercano a cero, pero mayor que este. En esta implementación se decidió utilizar el número 0,0001.

Esto también se hizo para el modelo PLIP ya que este constituye una generalización del modelo LIP.

Detalles de Implementación – Modelos

En el modelo SLIP si $sgn(v_1 + v_2) = 0$ entonces $\gamma_1 = \frac{sgn(v_1)}{sgn(v_1+v_2)}$ y $\gamma_2 = \frac{sgn(v_2)}{sgn(v_1+v_2)}$ se indefinen.

Solución: Cambiar, en la implementación, las definiciones por $\gamma_1 = sgn(v_1) \cdot sgn(v_1 + v_2)$ y $\gamma_2 = sgn(v_2) \cdot sgn(v_1 + v_2)$.

Experimentos – Curvas de los Modelos no Parametrizados

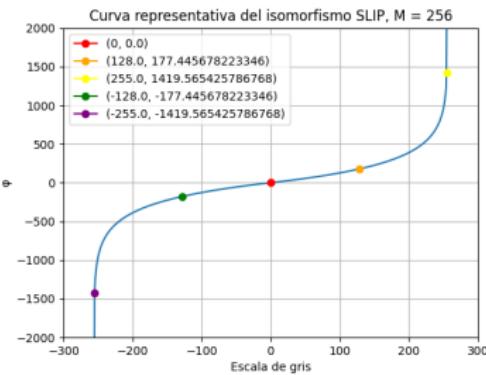
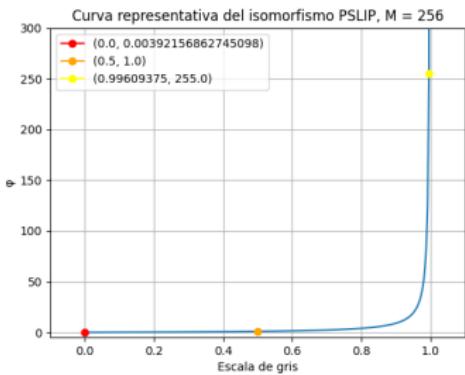
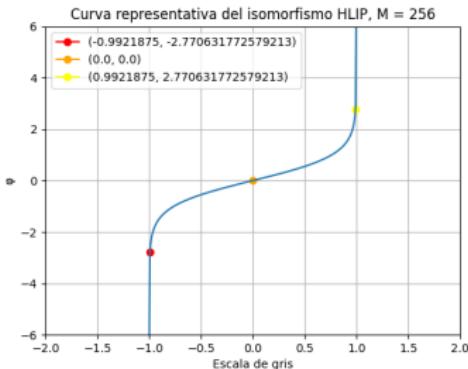
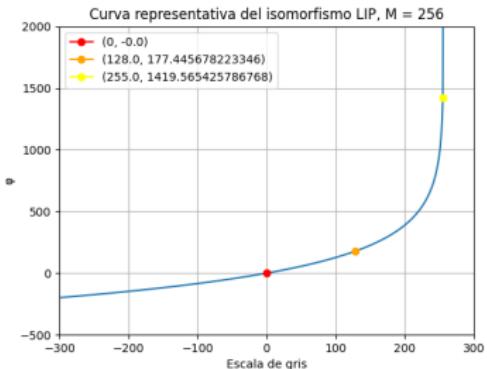
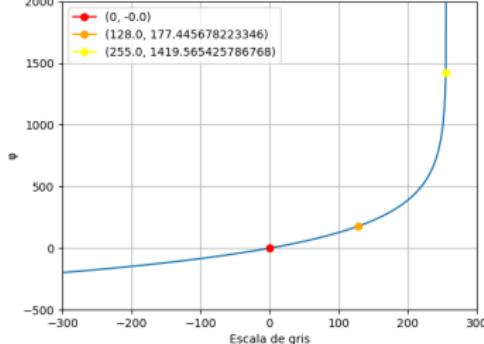


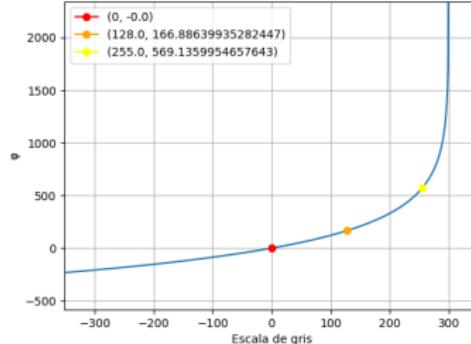
Figura: Curvas representativas de los modelos no parametrizados.

Experimentos – Curvas del Modelo PLIP

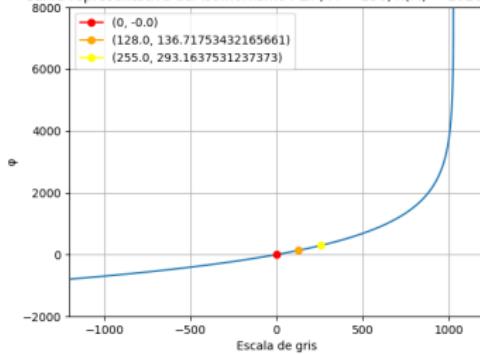
Curva representativa del isomorfismo PLIP, $M = 256$, $\lambda(M) = 256$, $\beta = 1$



Curva representativa del isomorfismo PLIP, $M = 256$, $\lambda(M) = 300$, $\beta = 1$



Curva representativa del isomorfismo PLIP, $M = 256$, $\lambda(M) = 1026$, $\beta = 1$



Curva representativa del isomorfismo PLIP, $M = 256$, $\lambda(M) = 4100$, $\beta = 1$

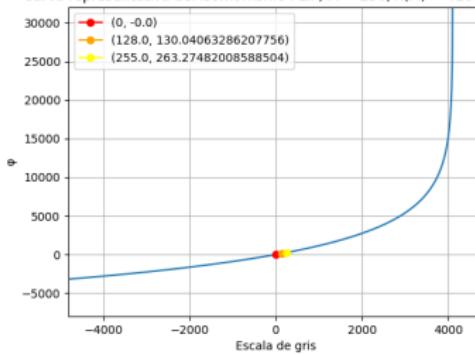


Figura: Curvas representativas del modelo PLIP con diferentes valores de $\lambda(M)$.

Experimentos – Curvas del Modelo PPSLIP

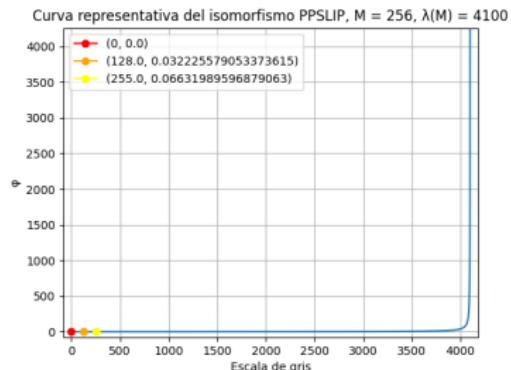
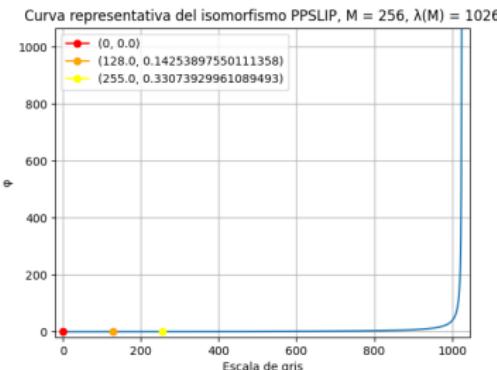
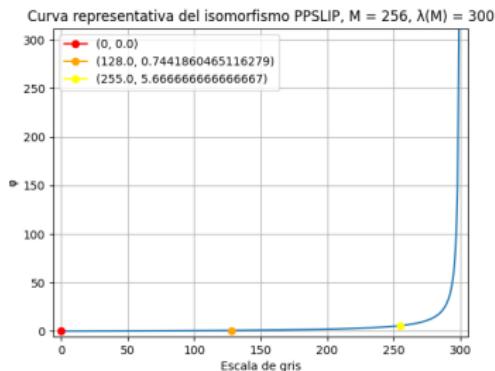
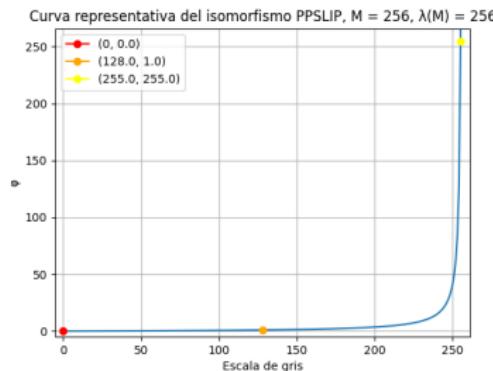


Figura: Curvas representativas del modelo PPSLIP, diferentes valores de $\lambda(M)$.

Experimentos – Suma de Imágenes



(a) Playa



(b) Patineta



(c) Montaña



(d) Insecto

Figura: Imágenes para los experimentos de suma.

Experimentos – Suma de Imágenes – Playa y Patineta



(a) Lineal $C_p = 3,49$



(b) LIP $C_p = 5,71$



(c) HLIP $C_p = 4,96$



(d) PSLIP $C_p = 1,39$



(e) SLIP $C_p = 1,45$



(f) PLIP $C_p = 5,71$



(g) PPSLIP $C_p = 3,35$

Experimentos – Suma de Imágenes – Montaña e Insecto



(h) Lineal $C_p = 3,15$



(i) LIP $C_p = 2,77$



(j) HLIP $C_p = 4,53$



(k) PSLIP $C_p = 3,47$



(l) SLIP $C_p = 3,65$

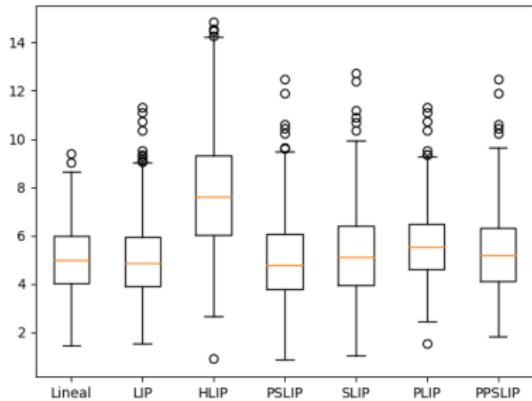


(m) PLIP $C_p = 3,13$



(n) PPSLIP $C_p = 3,47$

Experimentos – Suma de Imágenes – Estadísticas



(a) Diagramas de caja para la medida C_p .

Modelo	Media	Mediana
Lineal	5,05	4,98
LIP	5,00	4,85
HLIP	7,73	7,59
PSLIP	4,95	4,78
SLIP	5,24	5,08
PLIP	5,60	5,54
PPSLIP	5,35	5,20

(b) Media y mediana del valor de C_p .

Figura: Análisis estadístico de la operación suma de los diferentes modelos utilizando imágenes naturales.

Experimentos – Imágenes Utilizadas



(a) Cámara $C_p = 5,00$



(b) Tórax 1 $C_p = 2,26$

Figura: Imágenes para los experimentos de detección de bordes.

Experimentos – Detección de Bordes – Cámara



(a) Lineal $C_p = 4,69$



(b) LIP $C_p = 7,43$



(c) HLIP $C_p = 8,05$



(d) PSLIP $C_p = 9,41$



(e) SLIP $C_p = 6,26$



(f) PLIP $C_p = 7,43$



(g) PPSLIP $C_p = 9,41$

Figura: Filtro de Scharr aplicado a la imagen Cámara con los diferentes modelos.

Experimentos – Detección de Bordes – Tórax 1



(a) Lineal $C_p = 2,89$



(b) LIP $C_p = 3,66$



(c) HLIP $C_p = 4,40$



(d) PSLIP $C_p = 9,73$



(e) SLIP $C_p = 6,85$



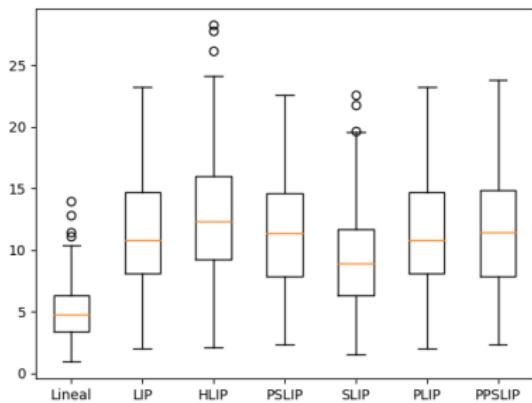
(f) PLIP $C_p = 3,66$



(g) PPSLIP $C_p = 9,73$

Figura: Filtro de Scharr aplicado a la imagen Tórax 1 con los diferentes modelos.

Experimentos – Detección de Bordes – Estadísticas



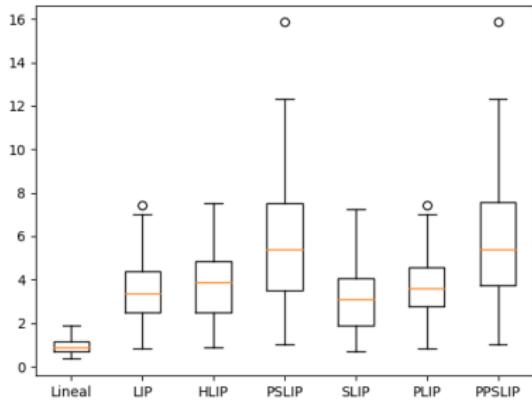
(a) Diagramas de caja para la medida C_p .

Modelo	Media	Mediana
Lineal	5,02	4,75
LIP	11,55	10,82
HLIP	12,81	12,36
PSLIP	11,57	11,38
SLIP	9,30	8,91
PLIP	11,59	10,82
PPSLIP	11,65	11,47

(b) Media y mediana del valor de C_p .

Figura: Análisis estadístico para la medida C_p utilizando los diferentes modelos para la detección de bordes en imágenes naturales.

Experimentos – Detección de Bordes – Estadísticas



(a) Diagramas de caja para la medida C_p .

Modelo	Media	Mediana
Lineal	0,96	0,89
LIP	3,48	3,38
HLIP	3,69	3,85
PSLIP	5,55	5,38
SLIP	3,11	3,09
PLIP	3,68	3,60
PPSLIP	5,64	5,41

(b) Media y mediana del valor de C_p .

Figura: Análisis estadístico para la medida C_p utilizando los diferentes modelos para la detección de bordes en imágenes de radiografías de tórax.

Experimentos – Unsharp Masking – Cámara



(a) Lineal $C_p = 4,13$



(b) LIP $C_p = 5,14$



(c) HLIP+ $C_p = 5,66$



(d) HLIP- $C_p = 5,73$



(e) PSLIP $C_p = 4,84$



(f) SLIP $C_p = 5,16$



(g) PLIP $C_p = 5,14$



(h) PPSLIP $C_p = 5,80$

Figura: Unsharp masking aplicado a la imagen Cámara con los diferentes modelos.

Experimentos – Unsharp Masking – Tórax 1



(a) Lineal $C_p = 2,60$



(b) LIP $C_p = 2,53$



(c) HLIP+ $C_p = 3,46$



(d) HLIP- $C_p = 2,62$



(e) PSLIP $C_p = 2,52$



(f) SLIP $C_p = 2,59$



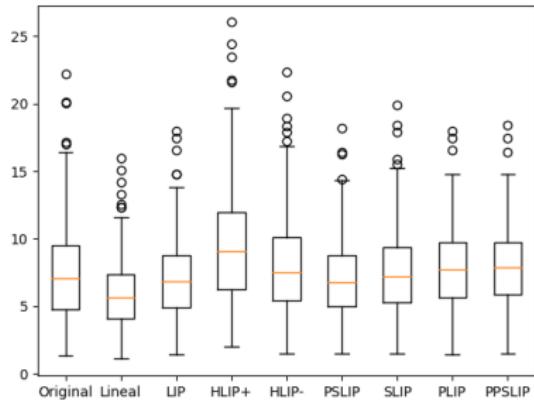
(g) PLIP $C_p = 2,53$



(h) PPSLIP $C_p = 4,97$

Figura: Unsharp masking aplicado a la imagen Tórax 1 con los diferentes modelos.

Experimentos – Unsharp Masking – Estadísticas



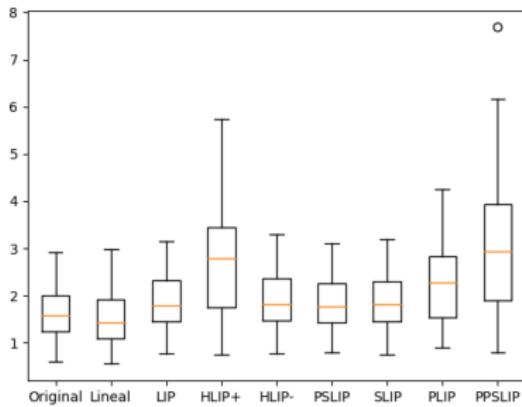
(a) Diagramas de caja para la medida C_p .

Modelo	Media	Mediana
Original	7,63	7,07
Lineal	6,04	5,66
LIP	7,24	6,81
HLIP+	9,67	9,07
HLIP-	8,23	7,52
PSLIP	7,10	6,73
SLIP	7,65	7,24
PLIP	7,95	7,72
PPSLIP	7,99	7,84

(b) Media y mediana del valor de C_p .

Figura: Análisis estadístico para la medida C_p utilizando los diferentes modelos para el algoritmo *unsharp masking* en imágenes naturales.

Experimentos – Unsharp Masking – Estadísticas



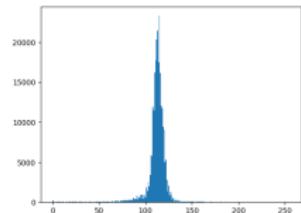
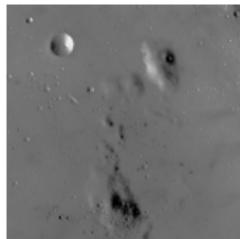
(a) Diagramas de caja para la medida C_p .

Modelo	Media	Mediana
Original	1,64	1,57
Lineal	1,49	1,42
LIP	1,88	1,78
HLIP+	2,71	2,78
HLIP-	1,91	1,82
PSLIP	1,84	1,78
SLIP	1,87	1,80
PLIP	2,21	2,27
PPSLIP	3,00	2,94

(b) Media y mediana del valor de C_p .

Figura: Análisis estadístico para la medida C_p utilizando los diferentes modelos para el algoritmo *unsharp masking* en imágenes de radiografías de tórax.

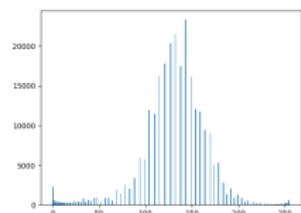
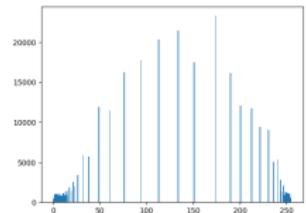
Experimentos – Transformación Afín – Luna



(a) Original
 $C_p = 1,30$



(c) Ecualizada
 $C_p = 10,86$



(e) HLIP
 $C_p = 5,35$



(g) SLIP
 $C_p = 5,07$

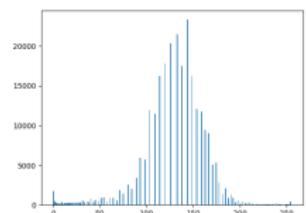
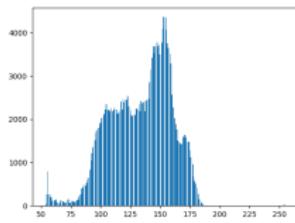


Figura: Diferentes técnicas de modificación del histograma de la imagen Luna.

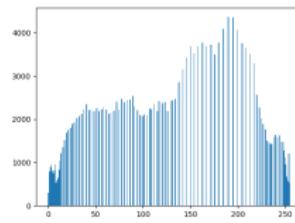
Experimentos – Transformación Afín – Tórax 2



(a) Original $C_p = 1,05$



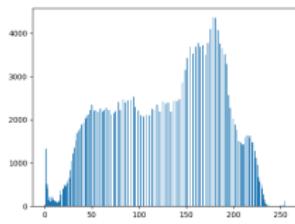
(c) Ecualizada $C_p = 2,82$



(d) Ecualizada Histograma



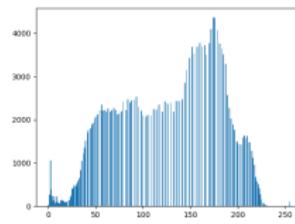
(e) HLIP $C_p = 2,36$



(f) HLIP Histograma



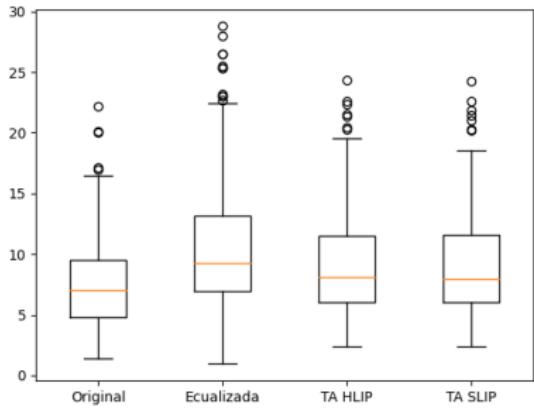
(g) SLIP $C_p = 2,19$



(h) SLIP Histograma

Figura: Diferentes técnicas de modificación del histograma de la imagen Tórax 2.

Experimentos – Transformación Afín – Estadísticas



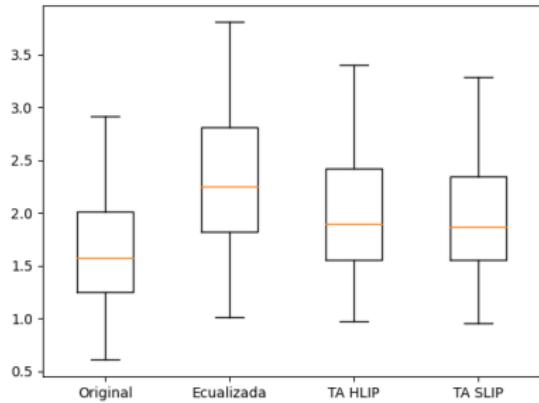
(a) Diagramas de caja para la medida C_p .

Modelo	Media	Mediana
Original	7,63	7,07
Ecualización	10,75	9,29
TA HLIP	9,20	8,07
TA SLIP	9,11	7,94

(b) Media y mediana del valor de C_p .

Figura: Análisis estadístico para la medida C_p utilizando los diferentes algoritmos para la modificación del histograma en imágenes naturales.

Experimentos – Transformación Afín – Estadísticas



(a) Diagramas de caja para la medida C_p .

Modelo	Media	Mediana
Original	1,64	1,57
Ecualización	2,32	2,24
TA HLIP	2,01	1,89
TA SLIP	1,98	1,86

(b) Media y mediana del valor de C_p .

Figura: Análisis estadístico para la medida C_p utilizando los diferentes algoritmos para la modificación del histograma en imágenes de radiografías de tórax.

Conclusiones

- El modelo lineal mostró deficiencias en determinadas ocasiones, las cuales pueden ser resueltas por alguno de los modelos no lineales presentados.
- El modelo LIP presentó sensibilidad hacia las tonalidades oscuras, mientras que el SLIP sin expansión presenta sensibilidad hacia las tonalidades claras.
- El modelo HLIP demostró ser muy efectivo en los diferentes experimentos realizados dado su carácter simétrico.
- El modelo PSLIP demostró ser muy efectivo para la detección de bordes, fundamentalmente en los niveles de mayor intensidad, quedando a deber en los de menor intensidad.

Conclusiones

- La parametrización de los modelos demostró tener gran utilidad ya que permite cierta flexibilidad en favor de obtener mejores resultados.
- El algoritmo de transformación afín con los dos modelos utilizados puede dar como resultado una imagen de mejor contraste que la imagen original y más natural que la imagen ecualizada.
- La métrica C_p utilizada para evaluar los experimentos puede ser utilizada para la evaluación de distintos algoritmos para el procesamiento de imágenes.

Recomendaciones

- Continuar el estudio de estos modelos con el fin de profundizar más en sus ventajas y desventajas, así como de otros modelos no lineales para el procesamiento de imágenes.
- Implementar algoritmos que combinen dos o más modelos aprovechando las ventajas que ofrece cada uno.
- En los futuros estudios que se realicen, incluir también, como medida subjetiva, la opinión de diferentes usuarios con respecto a la calidad de los resultados obtenidos.
- Implementación de un algoritmo que permita estimar para un modelo parametrizado el mejor o los mejores parámetros para la realización de una determinada operación.

Paquete de Python para el procesamiento de imágenes usando varios modelos no lineales

Carlos Toledo Silva

Tutor
MSc. Damian Valdés Santiago

Universidad de La Habana

13 de diciembre 2022